一些可能遇到的问题

1. 爬取页面返回奇怪的 status code？

当浏览者访问一个网页时，浏览者的浏览器会向网页所在服务器发出请求。当浏览器接收并显示网页前，此网页所在的服务器会返回一个包含 HTTP 状态码（Status Code）的信息头（server header）用以响应浏览器的请求。

Status code 代表返回的 response 是否正确，通常返回的是 200（OK）。如果一个 url 可以从浏览器打开，但是 request 返回的却是不同的内容，或者什么都没有返回。通常而言可以通过设置 request 的 header 来修正。

例如下图，直接向豆瓣的某个页面发送 request，返回的内容为空，status 为 418：

```
>>> url = r'https://movie.douban.com/subject/1292001'
>>> res = requests.get(url)
>>> res.text
''
>>> res.status_code
418
>>>
```

The HTTP **418 I'm a teapot** client error response code indicates that the server refuses to brew coffee because it is a teapot. This error is a reference to Hyper Text Coffee Pot Control Protocol which was an April Fools' joke in 1998.

解决方案：写一个最基本的 header，加入“User-Agent”字段（具体内容可以通过浏览器随便访问一个页面，打开“开发者模式”（F12）的“网络”标签页查看 request header），重新发送请求，问题解决。

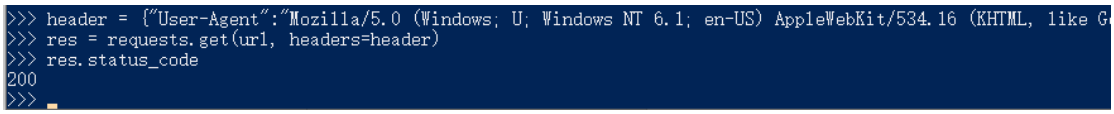

上述的“User-Agent”只是一个最简单的例子，header 里有许多字段，在互联网通信过程中 request 经常通过 header 向服务器表明自己的身份。不同的错误 status code 指代的错误也不一样，根据实际错误代码进行分析，或许需要别的解决方案。

参考链接：https://www.cnblogs.com/lei0213/p/6957508.html

2. 页面总是重定向到登录界面？

服务器可以根据 header 中的 cookie 检查当前使用用户的登录情况。通常而言信息类网站（微博、豆瓣等）往往只对游客展示很少或不展示信息，这时就需要向服务器表明自己的登录信息。然而爬虫实验中并没有给 header 中加入 cookie，所以服务器后端会返回一个登录的重定向页面。

解决方案：在 header 的 cookie 字段加入自己的 cookie，重新发送请求。自己的登录 cookie 可以先在浏览器登录一次，然后访问一个任意页面，然后仿照上例从“开发者模式”中获取这次请求中带的 cookie，加到爬虫的 header 里即可。

参考链接：https://www.douban.com/note/264976536/

（仿照链接里设置 header 的方式，这个链接使用的是比较早的库，发送 request 的地方使用实验任务中的 request 库即可）

3. 爬虫运行一会儿就不返回数据了？

这种情况很可能是服务器的反爬虫策略导致的。服务器一旦检测到某一个来源在短时间内发出了过多请求，就会将其判别为脚本来源，并且暂时禁用该 IP 或 cookie。

解决方案：考虑引入 time 模块的 time.sleep 函数，在爬取几个页面后等待 1-3 秒。

4. 爬取的页面只有模板，想爬的数据没有渲染上来？

现在的网站很少有静态页面了，大多数页面都只提供一个通用的模板，当用户访问某个特定的对象（比如某个影片的介绍页面）时，JavaScript 代码会向后端 API 请求数据，当页面加载完成后再把数据渲染到页面上。但是基本的爬虫库只包含一个通信模块，获取到页面文本后无法继续执行 JS 代码，也无法渲染数据。

解决方案：学习使用 Python 的 selenium 模块，结合无头浏览器 PhantomJS 或者 Google Chrome 对应的 selenium WebDriver，实现一个“基于浏览器”的爬虫。这种爬虫会以浏览器的方式实际加载数据，获取到的页面文本也是渲染后的结果，但资源消耗较大。

参考链接：https://selenium-python.readthedocs.io/

https://www.jianshu.com/p/dd848e40c7ad

如果还有其他问题：

1. 面向 StackOverflow 的编程：https://stackoverflow.com/
2. 面向 CSDN 的编程
3. 在课程群里@助教
4. ~~面向百度知道的编程~~（不推荐）